



Universidad Autónoma de Querétaro
Facultad De Ingeniería



**FACULTAD DE
INGENIERÍA**

Predicción de Niveles de Agua

Aprendizaje Automático Proyecto Final

P R E S E N T A

Ing. Daniel Eduardo González Alvarado

Profesor

Dr. Marco Antonio Aceves Fernández

06 de Junio de 2025

Índice

1. Etapa 1: Definición del problema	1
1.1. Identificar los objetivos	1
1.2. Entender el contexto	1
1.3. Definir las preguntas clave	2
1.4. Identificar las métricas de éxito (KPI's)	3
1.5. Evaluar los recursos disponibles	3
1.6. Alcance del proyecto	3
1.7. Identificar las partes interesadas	3
2. Etapa 2: Recopilación de datos	4
2.1. Identificar fuentes	4
2.2. Evaluar la calidad de los datos	4
2.3. Determinar el alcance de los datos	4
2.4. Recopilar los datos	5
2.5. Organizar y almacenar los datos	5
2.6. Documentar los datos	5
2.7. Asegurar la privacidad y la seguridad de los datos	7
3. Etapa 3: Preprocesamiento de datos	7
3.1. Limpieza de datos	8
3.2. División de datos en conjuntos de entrenamiento y prueba	9
3.3. Documentación de procesos	9
4. Etapa 4: Análisis exploratorio	9
4.1. Resumen estadístico	9
4.2. Análisis de correlación	10
4.3. Análisis de Distribución de Variables	11
4.4. Identificación de Valores Atípicos	11
4.5. Exploración de Relación entre Variables	12
4.6. Segmentación de datos	12
4.7. Exploración de Series Temporales	12
5. Etapa 5: Selección del modelo	13
5.1. Entrenamiento	13
5.2. Ajuste de Hiperparámetros	13
5.3. Evaluación del Modelo	13
5.4. Optimización	14
5.5. Comparación entre Modelos	14
6. Etapa 6: Interpretación y comunicación de Resultados	15
6.1. Interpretación de Resultados	15
6.1.1. Predicciones	15
6.1.2. Estaciones Clave	16
6.2. Contextualización de los Resultados	19
6.3. Identificación de Insights	19

6.4. Preparación de Informes y Presentaciones	19
6.5. Propuesta de Acciones Recomendadas	19
6.6. Seguimiento y Revisión	20
7. Bibliografía	21

1. Etapa 1: Definición del problema

1.1. Identificar los objetivos

Para este proyecto planteamos como objetivo general la predicción de niveles de agua subterránea en pozos del estado de California en Estados Unidos, usando datos recolectados de estaciones de medición del Departamento de Recursos Hídricos (DWR Por sus siglas en ingles). Es importante seguir este objetivo por medio del enfoque SMART esto quiere decir que buscamos resultados e**S**pecíficos, siendo este el alcanzar una precisión con un error medio absoluto (MAE) menor a 0.5 metros en al menos el 80 % siendo un valor **M**edible de los pozos analizados. **A**lcanzable, mediante el uso de técnicas de ciencia de datos, aprendizaje automático y nuestra base de datos; **R**elevante, al apoyar la gestión eficiente del recurso hídrico frente a desafíos ambientales y de planificación; y limitado en el **T**iempo, al establecer un plazo máximo de 12 semanas para completar el desarrollo del sistema, con entregas parciales cada 3 semanas. Estos objetivos se mantendrán como guía fundamental durante todas las etapas del proyecto.

1.2. Entender el contexto

El agua subterránea representa aproximadamente el 30 % del agua dulce disponible en el mundo y constituye un recurso crítico para el abastecimiento agrícola, municipal e industrial. Su gestión eficiente se ha vuelto prioritaria ante la creciente escasez y demanda. En regiones como California, donde los sistemas hídricos son complejos y dependen tanto de fuentes naturales como de infraestructura artificial, el monitoreo del nivel freático es esencial para garantizar la sostenibilidad del recurso.

La base de datos utilizada en este proyecto proviene del Departamento de Recursos Hídricos (DWR) de California e incluye mediciones continuas y periódicas de pozos distribuidos en varios condados. Estas mediciones permiten construir series de tiempo que reflejan las variaciones del nivel del agua en respuesta a procesos de recarga (lluvia, escorrentía, retorno de irrigación) y descarga (bombeo, filtraciones). Dado que estas variaciones son altamente dinámicas y heterogéneas en el espacio y el tiempo, contar con modelos de predicción confiables es fundamental para los gestores del agua, agricultores y responsables de políticas públicas.

El uso de tecnologías de inteligencia artificial y ciencia de datos permite convertir estas series históricas en herramientas predictivas, capaces de anticipar fluctuaciones del nivel freático y apoyar la toma de decisiones frente a eventos críticos como sequías o sobreexplotación de acuíferos.




Figura 1: Formación y Distribución de Aguas Subterráneas[1]

1.3. Definir las preguntas clave

Durante el desarrollo del proyecto, tendremos en cuenta las siguientes preguntas que marcarán el curso que seguiremos:

- ¿Cuáles son los patrones temporales y estacionales observados en los niveles de agua subterránea en los distintos pozos monitoreados?
- ¿Cómo se relacionan los cambios en el nivel del agua con eventos externos como precipitaciones, periodos de sequía o variaciones en la actividad agrícola?
- ¿Es posible construir modelos predictivos confiables que permitan anticipar el comportamiento del nivel freático con base en datos históricos?
- ¿Qué tan preciso puede ser el modelo para distintos horizontes temporales de predicción?
- ¿Qué pozos o regiones presentan comportamientos críticos o de interés que requieran especial atención por parte de los gestores hídricos?
- ¿Cómo pueden integrarse estas predicciones en estrategias prácticas de gestión del recurso para mejorar la sostenibilidad y eficiencia del uso del agua?

1.4. Identificar las métricas de éxito (KPI's)

Para evaluar el rendimiento y utilidad del sistema desarrollado, propondremos las siguientes métricas clave:

- **Precisión del modelo:** Error medio absoluto (MAE) menor a 5 metros.
- **Cobertura de datos:** Porcentaje de series temporales completas o imputadas con alta confiabilidad.
- **Capacidad de alerta:** Identificación temprana de focos de alerta en estaciones críticas para determinar acciones anticipadas.

1.5. Evaluar los recursos disponibles

Para el desarrollo contaremos con estos recursos:

- **Datos:** Base de datos proporcionada por el Departamento de Recursos Hídricos (DWR) de California, con más de 1 millón de registros provenientes de pozos ubicados en diversos condados.
- **Frecuencia de medición:** Mediciones continuas (cada 15 minutos a 1 hora) y periódicas (mensuales).
- **Herramientas técnicas:** Lenguaje Python con bibliotecas como Pandas, Matplotlib, Scikit-learn y herramientas de análisis de series temporales.
- **Equipo humano:** Profesionales en ciencia de datos, programación y gestión de recursos hídricos.
- **Limitantes:** Variabilidad en la frecuencia de muestreo, presencia de datos faltantes y necesidad de limpieza y preprocesamiento.

1.6. Alcance del proyecto

Abarcaremos el procesamiento, análisis y modelado de series temporales de niveles de agua subterránea a partir de datos históricos recolectados por el Departamento de Recursos Hídricos (DWR) de California. Se incluyen actividades como la limpieza de datos, imputación de valores faltantes, análisis exploratorio de tendencias temporales y estacionales, desarrollo de modelos predictivos, y visualización de resultados. Quedan fuera del alcance actividades como la recolección de datos en campo, la instalación de sensores, el desarrollo de sistemas en tiempo real y la estimación de demanda hídrica o simulación operativa de acuíferos, ya que este trabajo se enfoca exclusivamente en la predicción basada en datos históricos disponibles.

1.7. Identificar las partes interesadas

Entre las partes interesadas se encuentran las agencias públicas encargadas de la gestión hídrica, como el Departamento de Recursos Hídricos (DWR), así como investigadores y académicos que estudian la dinámica del agua subterránea y su relación con el cambio climático. También son actores clave los agricultores y usuarios del agua que dependen directamente de este

recurso para sus actividades productivas, así como los tomadores de decisiones responsables de diseñar políticas de sostenibilidad. Finalmente, el equipo técnico de ciencia de datos participa activamente en el diseño, implementación y validación de los modelos predictivos desarrollados.

2. Etapa 2: Recopilación de datos

2.1. Identificar fuentes

Para nuestro proyecto tomaremos una base de datos disponible en el sitio web de Kaggle específicamente “Continuous Groundwater Level Measurements-2023” [2] el cual contiene información extraída del sitio oficial del DWR de California [3]. Esto nos permite trabajar con datos reales recolectados a lo largo de 54 años ya que contamos con datos desde 1969 hasta 2022.

2.2. Evaluar la calidad de los datos

El conjunto de datos cuenta con seis columnas de códigos de calidad (**WLM_RPE_QC**, **WLM_GSE_QC**, **RPE_WSE_QC**, **GSE_WSE_QC**, **WSE_QC**), las cuales proporcionan una evaluación del nivel de confiabilidad de cada medición. Los códigos utilizados tienen significados bien definidos, entre los que destacan:

- **1**: Dato bueno.
- **2, 10**: Medición buena o editada.
- **15**: Medición provisional.
- **25**: Valor posiblemente afectado por interferencia.
- **35**: Dato estimado basado en registros históricos.
- **255**: Dato no disponible o inválido.

Una proporción significativa de las observaciones contiene el código **255**, lo cual equivale a valores faltantes, aunque estén representados numéricamente. Esto se alinea con la presencia de valores **NaN** en columnas como **WLM_RPE** y **WSE**. La disponibilidad de estos códigos permite implementar filtros de calidad en el preprocesamiento de los datos, como la exclusión de datos no confiables o el análisis separado de datos estimados.

2.3. Determinar el alcance de los datos

El conjunto de datos cubre un total de 81,066 observaciones distribuidas en un periodo de 54 años, desde 1969 hasta 2022. Las mediciones provienen de 526 estaciones distintas de monitoreo de aguas subterráneas, distribuidas en varios condados. Cada fila representa una medición mensual del nivel de agua en una estación determinada, acompañada de distintas formas de cálculo del nivel del agua con base en referencias geodésicas (**WLM_RPE**, **WLM_GSE**, **RPE_WSE**, **GSE_WSE**, **WSE**) y sus respectivas evaluaciones de calidad.

Este amplio rango temporal y espacial permite realizar análisis espacio-temporales del comportamiento del nivel freático, así como generar modelos de predicción robustos para diversas regiones y condiciones hidrológicas. La granularidad mensual favorece el seguimiento de tendencias a mediano y largo plazo, así como la identificación de anomalías estacionales o asociadas a fenómenos externos como sequías o recargas pluviales.

2.4. Recopilar los datos

Como se mencionó, la DB fue obtenida desde la plataforma *Kaggle*, que aloja una recopilación de mediciones mensuales del nivel del agua subterránea en múltiples estaciones. La información abarca el periodo de 1969 a 2022 y se encuentra organizada en formato CSV, lo cual facilita su procesamiento y análisis mediante herramientas computacionales como Python. Esta fuente de datos proporciona una base confiable y accesible para desarrollar modelos predictivos en el ámbito hidrogeológico.

2.5. Organizar y almacenar los datos

Los datos fueron organizados inicialmente en un archivo CSV de estructura tabular, donde cada fila representa una observación mensual correspondiente a una estación de monitoreo específica. Las columnas incluyen identificadores de estación, fecha de medición, niveles de agua bajo diferentes referencias geodésicas, y códigos de calidad.

Para su análisis, el conjunto de datos fue cargado en estructuras *DataFrame* utilizando la biblioteca **pandas** en Python. Esta organización permite aplicar transformaciones, filtrados, imputaciones y visualizaciones de manera eficiente. A futuro, se podrían almacenar los datos preprocesados en formatos optimizados como **Parquet** o **HDF5**, en caso de querer buscar el escalamiento del análisis o integrarlo en sistemas de predicción automatizados.

2.6. Documentar los datos

Para asegurar la correcta interpretación y trazabilidad del conjunto de datos, se elaboró una documentación que describe el significado de cada columna, sus unidades de medida y los valores posibles. Las variables principales corresponden a mediciones de nivel de agua referidas a diferentes puntos geodésicos: **WLM_RPE** (desde un punto de referencia), **WLM_GSE** (desde el nivel del suelo), **WSE** (nivel total del agua), entre otras.

Además, se incorporaron códigos de calidad en columnas auxiliares como **WSE_QC**, **WLM_GSE_QC**, etc., los cuales fueron interpretados a partir de un archivo complementario que describe el significado de cada código numérico (por ejemplo: 1 = dato bueno, 255 = dato no disponible). Esta documentación también incluye metadatos sobre la fuente de los datos, el periodo de cobertura (1969–2022), el número de estaciones y el formato original del archivo.

La documentación se mantendrá actualizada a medida que se apliquen transformaciones, como imputación de valores faltantes, filtrado por calidad o agregación temporal.

Tabla 1: Descripción de las variables del conjunto de datos

Columna	Etiqueta	Descripción
STATION	Estación	Identificador único de la estación (clave en la base de datos). En la mayoría de los casos, corresponde al número estatal del pozo.
MSMT_DATE	Fecha de medición del nivel de agua	Fecha/hora (en PST) en la que se recolectó la medición del nivel de agua subterránea.
WLM_RPE	Elevación desde punto de referencia	Elevación desde un punto de referencia utilizada para recolectar la medición del nivel de agua.
WLM_RPE_QC	Código de calidad de WLM_RPE	Código que indica la calidad de la medición desde el punto de referencia.
WLM_GSE	Elevación desde superficie del suelo	Elevación de la superficie del suelo en el sitio del pozo.
WLM_GSE_QC	Código de calidad de WLM_GSE	Código que indica la calidad de la medición desde la superficie del suelo.
RPE_WSE	Profundidad desde referencia hasta nivel del agua	Profundidad hasta la superficie del agua en pies desde el punto de referencia.
RPE_WSE_QC	Código de calidad de RPE_WSE	Código que indica la calidad de la medición desde la referencia hasta el nivel del agua.
GSE_WSE	Profundidad desde superficie del suelo hasta el nivel del agua	Profundidad o distancia desde la superficie del suelo hasta la superficie del agua en pies.
GSE_WSE_QC	Código de calidad de GSE_WSE	Código que indica la calidad de la medición desde el suelo hasta el nivel del agua.
WSE	Elevación del nivel del agua	Elevación de la superficie del agua en pies sobre el nivel medio del mar (NAVD88).
WSE_QC	Código de calidad de WSE	Código que indica la calidad de la medición de la elevación del nivel del agua.

Para nuestro caso tomaremos estas columnas y las renombraremos para un entendimiento mas sencillo de la siguiente manera:

Tabla 2: Correspondencia entre nombres originales y nombres renombrados

Nombre original	Nuevo nombre	Etiqueta
STATION	estacion	Estación
MSMT_DATE	fecha_med	Fecha de medición
WLM_RPE	punto_ref_elevacion	Elevación desde punto de referencia
WLM_RPE_QC	calidad_rpe	Calidad RPE
WLM_GSE	elevacion_terreno	Elevación del terreno
WLM_GSE_QC	calidad_elv	Calidad elevación terreno
RPE_WSE	elevacion_superficie_agua	Profundidad desde referencia
RPE_WSE_QC	calidad_elvsp_agua	Calidad elevación superficial
GSE_WSE	prof_superficie_lvl_agua	Profundidad desde superficie del suelo
GSE_WSE_QC	calidad_prof_sp_lvl_agua	Calidad profundidad desde suelo
WSE	elev_agua	Elevación del nivel del agua
WSE_QC	cal_elev_agua	Calidad elevación del agua

2.7. Asegurar la privacidad y la seguridad de los datos

El conjunto de datos utilizado no contiene información personal ni identificadores sensibles, ya que se limita a variables técnicas relacionadas con niveles de agua subterránea, fechas y estaciones de monitoreo geográficas. Por lo tanto, los riesgos asociados a la privacidad son prácticamente nulos. Además de ser información de recursos del estado la cual es pública.

3. Etapa 3: Preprocesamiento de datos

Al iniciar nuestro análisis para el procesamiento siempre partimos de conocer nuestros datos por lo cual buscaremos conocer la calidad de nuestra DB la cual nos arroja esta información:

	Columna	Nulos	% Nulos	Tipos de Dato
0	estacion	0	0.00	str
1	fecha_med	0	0.00	str
2	punto_ref_elevacion	223	0.28	float
3	calidad_rpe	0	0.00	int
4	elevacion_terreno	566	0.70	float
5	calidad_elv	0	0.00	int
6	elevacion_superficie_agua	15122	18.65	float
7	calidad_elvsp_agua	0	0.00	int
8	prof_superficie_lvl_agua	15630	19.28	float
9	calidad_prof_sp_lvl_agua	0	0.00	int
10	elev_agua	15331	18.91	float
11	cal_elev_agua	0	0.00	int

Figura 2: Valores nulos iniciales

3.1. Limpieza de datos

La limpieza de datos consistió en identificar y tratar valores nulos, inconsistencias y duplicados en las series temporales de nivel de agua subterránea. Se aplicaron los siguientes procesos:

- Eliminación de registros duplicados por fecha y estación.
- Conversión correcta del tipo de dato para la columna de fechas.
- Uso de la función `imputar_serie_tiempo` para rellenar valores faltantes basado en la secuencia de valores a lo largo del tiempo en las variables clave: `prof_superficie_lvl_agua`, `elevacion_superficie_agua`, y `elev_agua`.
- Para columnas restantes con nulos como `punto_ref_elev`, ya que la cantidad de valores nulos en relación al total de datos era mínima se optó por aplicar como último recurso la función `rellenar_con_media_por_estacion`, y posteriormente una imputación global con la media de la columna cuando fue necesario.

Este proceso garantizó la continuidad de las series temporales sin introducir valores extremos ni artificiales.

Para la predicción de niveles de agua subterránea, se empleó el algoritmo *Random Forest* debido a su capacidad para manejar datos no lineales y su robustez ante valores atípicos y datos faltantes. Este modelo de aprendizaje supervisado, basado en un conjunto de árboles de decisión, permite capturar interacciones complejas entre variables y mejorar la precisión general mediante el principio de bagging.

- **Precisión:** Al combinar múltiples árboles, reduce el sobreajuste y mejora la generalización.

- **Manejo de datos faltantes:** Puede tolerar valores nulos sin necesidad de imputaciones complejas.
- **Importancia de variables:** Permite interpretar qué factores influyen más en la predicción del nivel de agua.
- **Escalabilidad:** Es eficiente en conjuntos de datos grandes y con múltiples características.

Estas ventajas lo hacen especialmente adecuado para el análisis de series temporales ambientales con variabilidad estacional y ruido inherente.

El uso del algoritmo *Random Forest* permite omitir varias etapas tradicionales de preprocesamiento. No es necesario aplicar normalización ni estandarización, ya que los árboles de decisión no se ven afectados por la escala de las variables. Tampoco se requiere la transformación de datos ni la reducción de dimensionalidad, dado que el modelo puede manejar distribuciones no normales y trabajar eficientemente con muchas características, además de ofrecer medidas internas de importancia de variables. El re-muestreo o balanceo de clases no aplica en este caso por tratarse de un problema de regresión y no de clasificación.

3.2. División de datos en conjuntos de entrenamiento y prueba

Para evaluar la capacidad nuestro modelo *Random Forest*, se dividieron los datos en dos subconjuntos: entrenamiento y prueba. Se utilizó una proporción del 70 % para el entrenamiento y el 30 % restante para la prueba, garantizando que ambas particiones tengan una distribución similar de las distintas estaciones y condiciones temporales. La segmentación se realizó conservando la secuencia temporal, evitando mezclar observaciones futuras en el conjunto de entrenamiento, lo cual es especialmente importante al trabajar con series de tiempo.

3.3. Documentación de procesos

Durante el desarrollo del proyecto se registraron todas las etapas del flujo de trabajo, desde la carga y limpieza de los datos hasta el entrenamiento y validación del modelo. Esto incluye la imputación de valores nulos utilizando estrategias específicas por estación, la selección de variables objetivo y predictoras, así como las decisiones tomadas en el preprocesamiento y modelado. Se anotaron también los criterios utilizados para la elección del algoritmo *Random Forest*, justificando su adecuación a la naturaleza de los datos. Toda esta documentación garantiza la trazabilidad del proceso, permite la reproducibilidad de los resultados y facilita futuras mejoras o adaptaciones del modelo a nuevos conjuntos de datos.

4. Etapa 4: Análisis exploratorio

4.1. Resumen estadístico

Para esta parte podemos obtener un resumen estadístico de las columnas seleccionadas. Este resumen incluye estadísticas como el número de valores no nulos (**count**), la media (**mean**), la desviación estándar (**std**), el valor mínimo (**min**), los percentiles 25 %, 50 % (mediana) y 75 % (25 %, 50 %, 75 %), y el valor máximo (**max**).

	punto_ref_elevacion	elevacion_terreno	elevacion_superficie_agua	prof_superficie_lvl_agua	elev_agua
count	80843.000000	80500.000000	65944.000000	65436.000000	65735.000000
mean	342.065483	341.046282	36.269621	34.490961	301.250402
std	973.933330	975.831024	33.236157	33.380057	981.717670
min	-0.570000	-3.170000	-11.949000	-14.749000	-165.659000
25%	45.010000	44.580000	12.892000	11.349750	20.651000
50%	132.450000	129.300000	25.996500	24.198000	95.306000
75%	210.080000	212.410000	49.317000	47.699000	148.613000
max	5495.260000	5492.010000	299.130000	297.010000	5491.840000

Figura 3: Resumen Estadístico por columna de nuestra DB

4.2. Análisis de correlación

Generamos nuestra matriz de correlación y obtenemos lo siguiente:

	punto_ref_elevacion	elevacion_terreno	elevacion_superficie_agua	prof_superficie_lvl_agua	elev_agua
punto_ref_elevacion	1.000000	0.999998	-0.049483	-0.052461	0.999428
elevacion_terreno	0.999998	1.000000	-0.049585	-0.052313	0.999426
elevacion_superficie_agua	-0.049483	-0.049585	1.000000	0.998496	-0.083245
prof_superficie_lvl_agua	-0.052461	-0.052313	0.998496	1.000000	-0.086117
elev_agua	0.999428	0.999426	-0.083245	-0.086117	1.000000

Figura 4: Matriz de correlación de nuestra DB

Como podemos ver en la Figura 4

- Existe una correlación casi perfecta entre `punto_ref_elevacion` y `elevacion_terreno` (**0.999**), lo nos indica que ambas variables contienen información muy similar. Podría considerarse eliminar una de ellas para evitar redundancia en los modelos.
- Las variables `elevacion_superficie_agua` y `prof_superficie_lvl_agua` presentan también una correlación casi perfecta (**0.998**), lo que hace sentido dada su relación física, ya que la profundidad hasta el nivel del agua suele derivarse directamente de la elevación superficial del agua.
- La variable `elev_agua` muestra una fuerte correlación con `punto_ref_elevacion` (**0.999**) y `elevacion_terreno` (**0.999**), lo cual es consistente, ya que el nivel del agua se mide respecto a estos puntos de referencia.
- Se observa una correlación negativa moderada entre la variable `elev_agua` y otras dos variables de nuestra DB, `elevacion_superficie_agua` y `prof_superficie_lvl_agua` (**-0.08**), lo cual indica que a mayor profundidad o menor elevación del agua superficial, el nivel de agua relativo disminuye.

4.3. Análisis de Distribución de Variables

Con base en lo visto en la Figura4 nuestras variables están altamente relacionadas, por lo cual nos enfocaremos principalmente en `prof_superficie_lv1_agua` por lo cual buscamos su distribución:




Figura 5: Distribución de valores de Profundidad de Superficie de Nivel de Agua

4.4. Identificación de Valores Atípicos

Mediante boxplots y el análisis de cuantiles, se identificaron valores atípicos que podrían corresponder a errores de medición, condiciones extremas o estaciones particulares.




Figura 6: Outliers de Profundidad de Superficie de Nivel de Agua

Como podemos ver en la Figura 6 tenemos una cantidad considerable de datos atípicos o outliers pero al revisar la Figura 5 podemos observar que justamente la media se encuentra entre 0 y 50 sin embargo existen pozos mucho más profundos pero escasos. Estos datos siguen siendo validos ya que estos pozos realmente existen y aportan información relevante por lo cual de decidió dejarlos.

4.5. Exploración de Relación entre Variables

Se analizaron relaciones específicas entre variables, como la influencia del mes del año sobre el nivel de agua. Esta relación nos muestra lo siguiente:




Figura 7: Relación entre mes y profundidad del nivel del agua

Como se puede observar en la Figura 7 el nivel de agua en promedio varia en relación al mes o cual coincide con los datos obtenidos del clima en California, donde la mayoría de la precipitación ocurre entre octubre y abril, lo que define una estación húmeda. Los meses más secos, y por lo tanto con menos lluvia, son de mayo a septiembre[4].

4.6. Segmentación de datos

Se segmentaron los datos por estación de medición para estudiar el comportamiento individual y detectar estaciones con comportamientos atípicos o en riesgo de agotamiento. También se exploraron agrupamientos por zonas geográficas o periodos temporales.

4.7. Exploración de Series Temporales

Se analizaron las series temporales de cada estación para identificar patrones estacionales, tendencias a largo plazo y fluctuaciones mensuales. Este análisis fue crucial para preparar las variables de entrada del modelo de predicción y definir la cantidad de rezagos (lags) a utilizar.

5. Etapa 5: Selección del modelo

5.1. Entrenamiento

Para el entrenamiento del modelo se utilizó el algoritmo **Random Forest**, una técnica de aprendizaje automático basada en conjuntos de árboles de decisión [5]. Este modelo fue entrenado utilizando el conjunto de datos procesado, con predictores derivados de series temporales y transformaciones estacionales (seno y coseno del mes). Se utilizó la variable objetivo correspondiente al nivel de agua subterránea, ajustando una predicción mensual por estación.

5.2. Ajuste de Hiperparámetros

El modelo fue ajustado con una selección manual de hiperparámetros como el número de árboles (`n_estimators`) y la profundidad máxima (`max_depth`). En este caso, se priorizó evitar el sobreajuste, por lo que se limitaron los niveles de profundidad y se evaluó el desempeño mediante validación cruzada.

5.3. Evaluación del Modelo

La evaluación del modelo se realizó utilizando métricas estándar como el **RMSE** (Raíz del Error Cuadrático Medio), **MAE** (Error Absoluto Medio) y el **R²** (Coeficiente de Determinación). Los resultados obtenidos fueron:

Métrica	Valor
RMSE	5.858
MAE	1.712
R ²	0.971

Tabla 3: Resultados del modelo Random Forest




Figura 8: Nivel de agua predicho y real

Como podemos ver nuestro modelo se ajusta bastante bien entre lo que predice y los datos reales

5.4. Optimización

El modelo mostró un buen desempeño desde su configuración inicial, por lo que no fue necesario aplicar técnicas avanzadas de optimización. Sin embargo, se validó su rendimiento sobre un conjunto de prueba y se verificó la importancia de características para entender el aporte relativo de cada variable predictora.

5.5. Comparación entre Modelos

Para evaluar el desempeño de distintos enfoques de predicción, se compararon dos modelos: **Random Forest (RF)** y **Long Short-Term Memory (LSTM)**. A continuación, se presenta un resumen comparativo con base en los resultados obtenidos y las características de cada modelo:

Modelo	RMSE	MAE	R^2
Random Forest (RF)	5.858	1.712	0.971
LSTM	0.333	0.206	0.598

Tabla 4: Comparación de métricas de desempeño entre modelos

Categoría	Random Forest (RF)	LSTM
Ventajas	Requiere menor preprocesamiento. Buena capacidad de generalización. Robusto a outliers y datos faltantes. Fácil interpretación de resultados.	Captura patrones temporales y secuenciales. Adecuado para predicción de series de tiempo. Buen desempeño en series bien entrenadas.
Desventajas	No modela dependencias temporales explícitamente. Limitado para secuencias largas o estacionales.	Mayor complejidad computacional. Requiere datos preprocesados y normalizados. Menor interpretabilidad. Mayor sensibilidad a sobreajuste.

Tabla 5: Ventajas y desventajas comparativas entre Random Forest y LSTM

Aunque el modelo **LSTM** mostró un mejor desempeño en términos absolutos de error (RMSE y MAE), su capacidad de generalización y coeficiente de determinación ($R^2 = 0,598$) fue considerablemente menor en comparación con **Random Forest** ($R^2 = 0,971$). Esto sugiere que RF logra explicar mejor la varianza del sistema en este conjunto de datos, siendo más robusto ante cambios entre estaciones. Por tanto, se seleccionó RF como el modelo principal para este estudio, dejando el modelo LSTM como una alternativa prometedora para exploraciones futuras con mayor profundidad temporal.

6. Etapa 6: Interpretación y comunicación de Resultados

6.1. Interpretación de Resultados

Los resultados obtenidos mediante los modelos Random Forest y LSTM indican una alta capacidad predictiva en la estimación de niveles de agua subterránea. El modelo Random Forest mostró un desempeño notable como podemos ver en la Tabla 4, lo cual refleja una buena capacidad de generalización y robustez ante valores atípicos. Por su parte, el modelo LSTM capturó mejor la dinámica temporal, permitiendo una proyección más realista en escenarios de largo plazo.

6.1.1. Predicciones

Con nuestro modelo ya entrenado predecimos el comportamiento proyectado a futuro y obtuvimos este resultado:




Figura 9: Predicción de Random Forest

A su vez hicimos una predicción similar con LSTM:




Figura 10: Predicción de LSTM


Podemos observar en la Figura 9 que después de unas pocas predicciones nuestro modelo predice un pico muy alto por lo cual se decidió no predecir más adelante ya que aunque es probable marca un pico muy alto en relación al histórico.

Por otro lado la predicción de LSTM en la Figura 10 muestra una curva más suave lo cual está más alineado al comportamiento histórico incluso podemos ver que continua con una tendencia a la baja.


6.1.2. Estaciones Clave

Ya que contamos con estas predicciones nos enfocamos en determinar cuales de nuestras estaciones se encuentran en riesgo de secarse o que presentan una predicción con esta tendencia. Las estaciones con mayor tendencia a quedar secas en orden de riesgo son:


- a. 48N05E14R001M
- b. 48N04E35C001M
- c. 22N02W30H002M
- d. 21N02W36A001M
- e. 22N02W01N002M
- f. 22N02W02J001M
- g. 17N02E25J001M
- h. 12N01W15N006M
- i. 22N02W01N001M
- j. 21N04W12A004M




a)




b)




c)




d)




e)




f)




g)



h)




i)




j)


Figura 11: Predicções por estação com maior riesgo de descenso.




a)




b)




c)




d)




e)




f)




g)



h)



i)



j)

Figura 12: Predicções por estação com tendência em aumento.

En la Figura 12 podemos ver las estaciones que tienen una tendencia a la alta en su nivel de agua las cuales son:

- a. 16N03W14H003M
- b. 12N02E23H002M
- c. 20N02W25F004M
- d. 12N01W04M001M
- f. 05N03E09L001M
- g. 19N02E13Q003M
- h. 11N03E02Q004M
- i. 29N04W20A003M
- j. 15N03W20Q003M
- k. 20N02W33B001M

6.2. Contextualización de los Resultados

Los modelos permiten anticipar tendencias decrecientes en ciertos pozos, asociadas potencialmente a temporadas secas, sobreexplotación o falta de recarga adecuada. Este análisis es particularmente relevante para regiones con estrés hídrico recurrente. Como se puede ver las estaciones del año impactan en el nivel de agua de los pozos. Sin embargo podemos observar que aunque estos cuerpos de agua vuelven a llenarse en la estación húmeda el consumo de agua en la estación seca es cada vez mayor por lo cual siguen teniendo una tendencia a la sequía.

6.3. Identificación de Insights

A partir de los resultados, se identificaron estaciones con alto riesgo de agotamiento futuro del nivel freático. En particular, se señalaron las 10 estaciones con mayor probabilidad de presentar descenso crítico, lo cual permite focalizar acciones de monitoreo y mitigación. De la misma manera podemos ver las 10 estaciones que tienen una tendencia subir sus niveles de agua las cuales nos muestran que existen zonas con mayor uso de agua y zonas que pueden representar recursos potenciales. Además, se observó una alta correlación entre el nivel y variables temporales como el mes del año, lo que resalta la estacionalidad del recurso.

6.4. Preparación de Informes y Presentaciones

Los resultados se compilaron en gráficas explicativas, mapas de riesgo y reportes técnicos. Se utilizaron visualizaciones como boxplots, matrices de correlación y proyecciones de series temporales para facilitar la comprensión por parte de tomadores de decisiones. Asimismo, se prepararon dashboards y presentaciones ejecutivas con lenguaje claro y visualmente atractivo.

6.5. Propuesta de Acciones Recomendadas

Con base en los resultados obtenidos, se recomienda implementar acciones de gestión del agua como:

- Monitoreo intensivo en las estaciones de mayor riesgo(Figura 11).
- Monitoreo intensivo en las estaciones de menor riesgo(Figura 12).
- Implementación de estrategias de rotación de recursos.

- Implementación de sistemas de captación de lluvia en la temporada húmeda.
- Promoción del uso responsable del agua en las zonas afectadas.
- Ajustes en políticas de extracción según predicciones estacionales.

6.6. Seguimiento y Revisión

Se sugiere un esquema de revisión periódica cada seis meses, basados en la estación seca y húmeda utilizando nuevos datos para re-entrenar los modelos y evaluar la evolución de los niveles. Este seguimiento permitirá validar la efectividad de las acciones implementadas y ajustar las estrategias en función de los resultados reales.

7. Bibliografía

Referencias

- [1] Iberdrola. *Iberdrola*. Imagen extraída del sitio web de Iberdrola. 2025. URL: <https://www.iberdrola.com>.
- [2] Ali Farahmandfar. *Continuous Groundwater Level Measurements (2023)*. Kaggle Dataset. 2023. URL: <https://www.kaggle.com/datasets/alifarahmandfar/continuous-groundwater-level-measurements-2023>.
- [3] California Department of Water Resources. *California Department of Water Resources*. Sitio web oficial. 2025. URL: <https://water.ca.gov>.
- [4] Weather Spark. *Clima promedio en California, Estados Unidos*. Datos meteorológicos históricos y promedio. 2025. URL: <https://es.weatherspark.com/countries/US/CA>.
- [5] Marco Antonio Aceves Fernandez. *Inteligencia Artificial Para Programadores Con Prisa*. Universo de Letras, 2021.