



Universidad Autónoma de Querétaro
Facultad De Ingeniería



**FACULTAD DE
INGENIERÍA**

Bases de Datos y Tipos de Variables

Aprendizaje Automático Practica 1

P R E S E N T A

Ing. Daniel Eduardo González Alvarado

Profesor

Dr. Marco Antonio Aceves Fernández

Enero 2025

Índice

1. Introducción	1
1.1. Bases de datos	1
1.2. Tipos de Variables	1
1.2.1. Variable Dependientes	1
1.2.2. Variable Independiente	1
1.2.3. Variable De Interacción	1
1.2.4. Variable Latente	1
1.2.5. Variable Confusora	1
1.2.6. Variable Correlacionada	2
1.2.7. Variable De Control	2
1.2.8. Variable Filtrante (Leaky)	2
1.2.9. Variable No Estacionaria	2
1.2.10. Variable Estacionaria	2
1.2.11. Variable Rezagada	2
2. Desarrollo	2
2.1. Wine Quality	2
2.2. Tourist Travel Modes in Europe	3
2.3. Flowers Recognition	4
3. Resultados	5
4. Discusión	6
5. Conclusion	6
6. Bibliografía	8

1. Introducción

1.1. Bases de datos

Las bases de datos son una colección organizada de datos. Estos datos son hechos; sin embargo, los hechos por sí mismos carecen de contexto. Por lo que necesitan ser interpretados y analizados. Es por esto que al asignarles un contexto y un orden a cada conjunto de datos podemos tener una base de datos.

Dicho esto, debemos notar que los atributos son una parte esencial de las bases de datos, ya que estos nos dan el contexto de los datos que estamos leyendo y, a su vez, estos atributos nos indican el tipo de variable que podemos obtener de ellos. Para esto, repasaremos los tipos de variables que existen.

1.2. Tipos de Variables

Los tipos de variables nos ayudan a manejar de manera correcta los datos que obtenemos de las bases de datos, es por esto que es importante saber identificarlas, ya que existen diferentes tipos, como los que mencionaremos a continuación.

1.2.1. Variable Dependientes

También llamada predictora es la que manipula o se utiliza para predecir el valor de otra variable.

1.2.2. Variable Independiente

También llamada respuesta, es la que se mide o se observa, y su valor depende de la variable independiente.

1.2.3. Variable De Interacción

Esta se crea a partir de un conjunto de variables originales para representar la interacción entre ellas.

1.2.4. Variable Latente

Suelen ser conceptos abstractos que no pueden ser medidos de manera directa, pero se pueden inferir a partir de otras variables. Ej. Inteligencia, bienestar, satisfacción, dolor, etc.

1.2.5. Variable Confusora

Esta se encuentra relacionada con la V. Independiente así como con la V. Dependiente, ya que puede distorsionar o sesgar los resultados. Puede hacer que parezca una relación directa entre la V.I. y la V.D. cuando en realidad esta relación está medida o influenciada por la variable confusora.

1.2.6. Variable Correlacionada

Las variables correlacionadas son dos variables cuantitativas que varían de manera sistemática entre sí. Esto significa que los valores de una variable cambian en relación con los valores de la otra.

1.2.7. Variable De Control

Una variable de control es un factor que se mantiene constante en un experimento para evitar que afecte los resultados. Se utilizan para eliminar o neutralizar los efectos de una V. Dependiente.

1.2.8. Variable Filtrante (Leaky)

Suele ser un atributo que de manera inapropiada contiene información sobre la variable objetivo (la que se intenta predecir) Pueden inflar artificialmente el rendimiento del modelo y hacer que parezca más preciso de lo que en realidad es.

1.2.9. Variable No Estacionaria

Estas variables suelen cambiar con el tiempo, ya sea en su tendencia, variabilidad, frecuencia o amplitud.

1.2.10. Variable Estacionaria

Al contrario de las V. no estacionarias, estas no cambian con el tiempo. Esto significa que sus parámetros estadísticos, como la media y la varianza, son constantes.

1.2.11. Variable Rezagada

Es una variable cuyo valor corresponde a un período de tiempo anterior al actual. En el análisis de series temporales y econometría, las variables rezagadas se utilizan para capturar los efectos retardados, es decir, el impacto que una variable puede tener en otra con un desfase temporal; en otras palabras, ayudan a predecir el comportamiento futuro.

2. Desarrollo

Para esta parte nos basaremos principalmente en motores de búsqueda de bases de datos. entre los más conocidos se encuentran kaggle, hugging Face, UCI y Google data search por mencionar algunos. Buscaremos bases de datos que sean interesantes de analizar. Para empezar tomaremos como ejemplo una DB sobre el vino rojo.

2.1. Wine Quality

Esta DB nos presenta informacion fisico-quimica sobre el vino tinto Portugués “Vinho Verde”. Los atributos de esta DB son:

1. fixed acidity
2. volatile acidity
3. citric acid
4. residual sugar
5. chlorides
6. free sulfur dioxide
7. total sulfur dioxide
8. density
9. pH
10. sulphates
11. alcohol
12. quality (score between 0 and 10)

Con estos atributos podemos ir develando el tipo de variable que son, para empezar al ver la DB podemos determinar que es de tipo estructurada al ser una tabla.

fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality
7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5
7.8	0.88	0	2.6	0.098	25	67	0.9968	3.2	0.68	9.8	5
7.8	0.76	0.04	2.3	0.092	15	54	0.997	3.26	0.65	9.8	5
11.2	0.28	0.56	1.9	0.075	17	60	0.998	3.16	0.58	9.8	6
7.4	0.7	0	1.9	0.076	11	34	0.9978	3.51	0.56	9.4	5
7.4	0.66	0	1.8	0.075	13	40	0.9978	3.51	0.56	9.4	5
7.9	0.6	0.06	1.6	0.069	15	59	0.9964	3.3	0.46	9.4	5
7.3	0.65	0	1.2	0.065	15	21	0.9946	3.39	0.47	10	7
7.8	0.58	0.02	2	0.073	9	18	0.9968	3.36	0.57	9.5	7
7.5	0.5	0.36	6.1	0.071	17	102	0.9978	3.35	0.8	10.5	5
6.7	0.58	0.08	1.8	0.097	15	65	0.9959	3.28	0.54	9.2	5
7.5	0.5	0.36	6.1	0.071	17	102	0.9978	3.35	0.8	10.5	5
5.6	0.615	0	1.6	0.089	16	59	0.9943	3.58	0.52	9.9	5
7.8	0.61	0.29	1.6	0.114	9	29	0.9974	3.26	1.56	9.1	5
8.9	0.62	0.18	3.8	0.176	52	145	0.9986	3.16	0.88	9.2	5
8.9	0.62	0.19	3.9	0.17	51	148	0.9986	3.17	0.93	9.2	5
8.5	0.28	0.56	1.8	0.092	35	103	0.9969	3.3	0.75	10.5	7
8.1	0.56	0.28	1.7	0.368	16	56	0.9968	3.11	1.28	9.3	5
7.4	0.59	0.08	4.4	0.086	6	29	0.9974	3.38	0.5	9	4
7.9	0.32	0.51	1.8	0.341	17	56	0.9969	3.04	1.08	9.2	6
8.9	0.22	0.48	1.8	0.077	29	60	0.9968	3.39	0.53	9.4	6
7.6	0.39	0.31	2.3	0.082	23	71	0.9982	3.52	0.65	9.7	5
7.9	0.43	0.21	1.6	0.106	10	37	0.9966	3.17	0.91	9.5	5
8.5	0.49	0.11	2.3	0.084	9	67	0.9968	3.17	0.53	9.4	5
6.9	0.4	0.14	2.4	0.085	21	40	0.9968	3.43	0.63	9.7	6
6.3	0.39	0.16	1.4	0.08	11	23	0.9955	3.34	0.56	9.3	5

Figura 1: Captura de DB Wine Quality

También podemos ver que esta DB es bastante sencilla ya que la mayoría de las variables son del tipo independientes. ya que no interactúan entre sí de ninguna manera.

2.2. Tourist Travel Modes in Europe

Partimos de nuevo de que es una DB estructurada al estar los datos es una tabla donde los atributos son:

1. Tourist ID
2. Country Visited
3. City Visited
4. Mode of Travel
5. Travel Duration Days
6. Number of Companions
7. Total Travel Cost
8. Accommodation Type
9. Main Purpose
10. Season of Visit

Tourist_ID	Country_Visited	City_Visited	Mode_of_Travel	Travel_Duration_Days	Number_of_City_Visits	Total_Travel_Accommodation	Main_Purpose_of_Visit	Season_of_Visit
1	Germany	Hamburg	Flight	8	4	1060 Hotel	Family Visit	Summer
2	Germany	Berlin	Car	16	3	3972 Hostel	Family Visit	Winter
3	UK	Manchester	Bicycle	8	2	666 Camping	Business	Winter
4	Greece	Thessaloniki	Bicycle	12	3	3644 Hotel	Business	Summer
5	Greece	Thessaloniki	Flight	5	3	1885 Airbnb	Leisure	Spring
6	Greece	Athens	Bicycle	3	4	2633 Hostel	Family Visit	Summer
7	Portugal	Lisbon	Bus	2	4	3585 Hostel	Leisure	Winter
8	Greece	Athens	Train	13	1	674 Camping	Leisure	Winter
9	Portugal	Faro	Bus	11	4	2947 Camping	Leisure	Winter
10	UK	Manchester	Flight	17	3	2099 Hostel	Business	Summer
11	Portugal	Lisbon	Flight	4	5	4090 Hostel	Business	Summer
12	Greece	Athens	Flight	8	5	3088 Airbnb	Family Visit	Spring
13	Spain	Madrid	Car	8	2	2635 Hostel	Business	Summer
14	Austria	Salzburg	Bus	15	2	2241 Camping	Business	Summer
15	Germany	Berlin	Train	10	2	2812 Hostel	Family Visit	Winter
16	Portugal	Lisbon	Flight	3	4	1678 Hotel	Business	Fall
17	UK	London	Train	13	5	975 Airbnb	Business	Spring
18	Italy	Rome	Train	16	3	3352 Airbnb	Business	Summer
19	Netherlands	Utrecht	Train	5	2	4143 Camping	Business	Spring
20	France	Paris	Bus	5	2	1221 Hotel	Leisure	Spring
21	Switzerland	Lucerne	Car	7	2	4043 Hotel	Family Visit	Spring
22	Portugal	Porto	Train	19	2	361 Hostel	Leisure	Fall
23	Germany	Hamburg	Bus	11	4	3542 Airbnb	Leisure	Summer
24	Italy	Rome	Train	9	4	1216 Hostel	Family Visit	Fall
25	Greece	Athens	Bicycle	9	5	537 Airbnb	Business	Winter

Figura 2: Captura de DB Tourist Travel Modes in Europe

En La Figura 2 podemos ver que sí existen diferentes tipos de variables, por ejemplo, “City Visited” es una variable dependiente de “Country Visited” ya que las ciudades están ligadas a los países que se visitan. De la misma manera podemos observar una relación entre “Mode of Travel” y “Travel Duration Days” sin embargo podríamos decir que “Travel Duration Days” es una variable confusora, ya que aunque esta relacionada, no es dependiente directamente.

2.3. Flowers Recognition

En esta BD podemos ver que se clasifican 5 tipos de flores, estas están etiquetadas en forma de carpetas que contienen un tipo específico de flor. En este caso al ser una BD de datos de imágenes para determinar las variables tenemos que tener en cuenta, que los atributos pueden ser información de las imágenes como alto, ancho, canales y en algunos casos incluso profundidad.

Etiqueta	Imagen
Daisy	
Rose	
Dandelion	
Sunflower	
Tulip	

Cuadro 1: Imágenes de Muestra de la DB Flowers Recognition

En este caso todos estos atributos son variables independientes ya que las dimensiones de la imagen no se afectan entre sí. En caso de los canales nos apoyamos de python y la librería opencv-python para determinar cuantos canales tiene, en la mayoría de los casos son 3 canales, los cuales son RGB por sus siglas en inglés (Red, Green, Blue). Al hacer esto obtenemos como respuesta: (405, 614, 3) para la imagen de los tulipanes del Cuadro 1, estos datos son el ancho, alto y los canales. Estos mismos canales pueden ser separados y obtenidos de manera independiente, esto se considera un pre-procesamiento de imágenes.

3. Resultados

Como podemos observar las bases de datos seleccionadas las variables independientes predominan en este caso sin embargo no siempre será el caso, para esto tomemos en cuenta la segunda base de datos (Tourist Travel Modes in Europe) en esta contamos con varias relaciones de las variables que nos permiten observar un caso de variables dependientes. El caso de la última base de datos (Flowers Recognition) es interesante de analizar ya que los atributos no se observan de manera directa, sin embargo si están a la vista tomando como ejemplo principal el tamaño de la imagen.

4. Discusión

En que se podría usar o que análisis se podría usar para que los datos son buenos etc

Tomando en cuenta que la DB (Wine Quality) tiene mas parámetros enfocados en su elaboración y sus componentes podríamos explorar las propiedades que tienen al estar en barriles de diferentes maderas así como el tipo de uva que se utiliza, cuando se cosecho e incluso si la maduración de la uva estuvo acompañada de sequías, lluvias, tormentas o algún parámetro que nos permita tener en cuenta el clima. Esto nos permitiría proporcionar mas datos para posteriormente dar esta información a una nueva población muestra con el fin de crear una nueva DB calificando los mismos vinos.

Para la segunda DB (Tourist Travel Modes in Europe) puede servir para predecir el comportamiento de los vuelos así como el de la cantidad de gente que visita cada ciudad y país en cada temporada del año, permitiéndonos tomarlas como variables rezagadas que nos permitan predecir el comportamiento de visitas.

Por ultimo la DB (Flowers Recognition) cuenta con una limitante importante y es que al solo tener 5 etiquetas (5 tipos de flores) nos limita su uso ya que aunque se agreguen mas imágenes y ser muy preciso para detectarlas no podría diferenciar flores que no conozca. Sin embargo esto seria parte del uso que se le vaya a dar, ya que esta misma limitante es su punto fuerte si nos encontráramos en un jardín repleto de flores de diferentes tipos y quisiéramos solo encontrar las 5 especies que tenemos seria una gran herramienta.

5. Conclusion

Tu opinion sobre los datos

La primer base de datos (Wine Quality) a pesar de contener solamente variables independientes cuenta con una característica importante y es que su ultimo atributo (Quality) es una variable latente, ya que aunque podemos medir e indicar de manera presida sus otros atributos la calidad del vino puede ser interpretada de manera diferente por cada persona, esto nos podría llevar a generar mas datos a partir de un muestreo mas grande, por ejemplo el dar muestras de cada vino y medir la satisfacción del vino basándonos en si la persona lo disfruto, si le gustaría repetir o si estaría dispuesto a comprarlo, todo esto nos genera nuevas variables que podrían ser dependientes en el caso de las ultimas dos mencionadas.

Para la segunda base de datos (Tourist Travel Modes in Europe) podemos usar estos datos para determinar temporadas altas y bajas para visitar alguna ciudad o pais en particular, tomemos por ejemplo las ciudades que cuentan con costa tienen una mayor cantidad de visitas por ocio durante el verano, mientras que los países con montañas suelen contar con mas visitas durante el inviernos. De la misma manera podemos ver que la mayoría de personas que viajan por negocios prefieren alojarse en hoteles, esto podría servir a hacer estrategias de negocios dando precios especiales en hoteles cuando se sabe que las personas viajan por negocios.

Por ultimo se escogió una base de datos de imágenes (Flowers Recognition) para poder explorar otro tipo de base de datos esta cuenta con la característica especial de que las imágenes cuentan con una etiqueta para que un modelo entrenado con esta DB pueda identificar el tipo de flor que se le muestre, sin embargo debemos tener en cuenta que esto solo sera posible para los tipos de flores con las cuales se entreno el modelo por lo que solo tratara de buscar estas 5 especies sin considerar otras, es decir si le mostramos una imagen de un lirio o un clavel no

podrá identificar la especie. Esto nos deja ver que puede ser muy preciso en casos específicos sin embargo no lo será en casos más generales.

6. Bibliografía

Aceves Fernández, M. A. (2021). Inteligencia Artificial para Programadores con Prisa. Independently Published.

Beynon-Davies, P. (2018). Sistemas de bases de datos. Reverte.

Choudhary, A. (2025). Tourist Travel Modes in Europe Dataset [Data set].

Kaggle: Your machine learning and data science community. (s/f). Kaggle.com. Recuperado el 30 de enero de 2025, de <https://www.kaggle.com>

Mamaev, A. (2021). Flowers Recognition [Data set].

Paulo Cortez, A. Cerdeira, F. Almeida, T. Matos, J. Reis. (2009). Wine Quality [Data set]. UCI Machine Learning Repository.

The AI community building the future. (s/f). Huggingface.co. Recuperado el 30 de enero de 2025, de <https://huggingface.co>

UCI machine learning repository. (s/f). Uci.edu. Recuperado el 30 de enero de 2025, de <https://archive.ics.uci.edu>