



Universidad Autónoma de Querétaro
Facultad De Ingeniería



**FACULTAD DE
INGENIERÍA**

Protocolo de Adquisición de Datos

Aprendizaje Automático Practica 2

P R E S E N T A

Ing. Daniel Eduardo González Alvarado

Profesor

Dr. Marco Antonio Aceves Fernández

14 de febrero de 2025

Índice

1. Introducción	1
1.1. Datos Cualitativos	1
1.2. Datos Cuantitativos	1
1.3. Factores de un Protocolo de Adquisición de Datos	2
1.3.1. Definir las preguntas	2
1.3.2. Establecer Prioridades	2
1.3.3. Recopilar Datos	2
1.3.4. Analizar datos	2
1.3.5. Consideraciones Extras	2
1.4. Etapas del Muestreo	2
1.4.1. Muestra	2
1.4.2. Cobertura	3
1.4.3. Fecha y Duración	3
1.4.4. Población	3
1.4.5. Tamaño de la Muestra	3
2. Desarrollo	3
2.1. Consideraciones Previas	3
2.2. Recolección de Datos	4
2.3. Propuesta de Protocolo	4
3. Resultados	5
3.1. Comparación de Protocolos	5
4. Discusión	6
5. Conclusión	7
6. Bibliografía	9

1. Introducción

En la actualidad, vivimos en un mundo más conectado, más rodeados de información al alcance de nuestros dedos; sin embargo, esto quiere decir que, de la misma manera, existen miles de millones de datos que nos rodean y que, sin saberlo, generamos cada segundo. Tan solo Google, el buscador más grande del mundo, tiene billones de búsquedas por segundo, en Youtube se suben más de 300 horas de video por minuto, lo que equivale a 720 mil horas al día. Esto significa que cada minuto se suben 500 horas de video, o 1250 días de videos por hora. Esto representa una cantidad masiva de datos, sin embargo, no tenemos que ir tan lejos, en el día a día con nuestros dispositivos móviles generamos datos de búsquedas, sobre lo que nos gusta y a dónde vamos, mientras que con los dispositivos wearables nosotros mismos generamos datos, como nuestras rutinas de ejercicio, horas de sueño, frecuencia cardíaca, entre otros.

Es crucial gestionar adecuadamente la abundante información disponible, lo que presenta un desafío para distinguir entre datos relevantes y no relevantes. Además, es necesario limpiar y organizar estos datos, utilizando diversas estrategias. Una forma de comenzar a estructurar los datos es clasificándolos en dos grandes categorías.

1.1. Datos Cualitativos

Los datos cualitativos son aquellos que nos muestran información de manera verbal o gráfica es decir, toda aquella información que se pueda representar de manera textual o gráfica.

Nombre	Edad	Ocupación	Horas de Sueño
Juan Pérez	25	Estudiante	7
María Gómez	34	Ingeniera	6
Carlos López	42	Médico	5
Ana Martínez	29	Diseñadora	8
Luis Ramírez	50	Profesor	6.5

Tabla 1: Horas de Sueño

Si observamos la Tabla 1 podemos determinar que la Ocupación, como el Nombre, son datos cualitativos.

1.2. Datos Cuantitativos

Los datos cuantitativos son aquellos que se pueden representar de manera numérica o matemática. Tomemos como referencia la Tabla 1 aquí podemos ver los datos como edad y horas de sueño.

En resumen,

- Datos Cualitativos: Datos representados de manera verbal o gráfica.
- Datos Cuantitativos: Datos representados de manera numérica.

Teniendo esto en cuenta, tener una buena base de datos se basa en tener un buen protocolo de adquisición de datos y, para empezar con esto, debemos tener en cuenta los siguientes factores[1].

1.3. Factores de un Protocolo de Adquisición de Datos

1.3.1. Definir las preguntas

Partimos de determinar ¿qué datos quiero?, ¿para qué los voy a utilizar?, ¿qué tipo de pre-procesamiento necesito?, ¿cuántos datos necesito como mínimo? Si tenemos estas preguntas en cuenta, podemos hacer una delimitación de los datos más eficiente y, con esto, podemos tener datos más precisos y que, a su vez, serán más significativos para nuestro modelo.

1.3.2. Establecer Prioridades

Es importante saber qué datos son prioridad para nosotros, así como cuáles podemos conseguir de primera mano, cuáles podemos obtener de bases de datos ya existentes, si es que son de fuentes fiables, y de la misma manera saber cuál es el nivel de acceso a los datos, si son públicos, necesitan una licencia, están ligados a algún tipo de privacidad, etc.

1.3.3. Recopilar Datos

Una vez que ya tenemos claros los datos que necesitamos y cuáles son más prioritarios para nosotros, podemos empezar a recolectar nuestros datos. Para esto, también es importante saber cuál es la mejor manera de hacer esto. Tenemos diferentes opciones como APIs, web scraping, encuestas, dispositivos de medición, etc. Cada una de estas opciones a su vez cuenta con diferentes herramientas de recolección que se deben tener en cuenta ya que cada una cuenta con ventajas y desventajas.

1.3.4. Analizar datos

Dentro de nuestro análisis de datos debemos tener en cuenta la distribución de los datos, tendencia, datos atípicos, si existen datos faltantes y también debemos determinar por qué es que cualquiera de estas situaciones está presente.

1.3.5. Consideraciones Extras

Mientras que los puntos anteriores son prioritarios, podemos tener consideraciones extras para una buena base de datos; por ejemplo: tener consideraciones éticas en la adquisición y uso de datos, especialmente si se trata de datos personales o sensibles.

1.4. Etapas del Muestreo

Una vez que tenemos claros los factores de nuestro protocolo de adquisición de datos, es momento de lanzarnos de lleno en el muestreo de los datos y para esto seguiremos varias etapas, las cuales son:

1.4.1. Muestra

La muestra representa un subconjunto de la población de estudio, seleccionado mediante criterios específicos para garantizar la validez y representatividad de los resultados.

1.4.2. Cobertura

La cobertura hace referencia al alcance geográfico y demográfico del estudio, asegurando que la muestra incluya a los elementos relevantes de la población objetivo.

1.4.3. Fecha y Duración

Esta etapa define el período en el que se lleva a cabo el muestreo, indicando las fechas específicas de recolección de datos y la duración total del proceso.

1.4.4. Población

La población se refiere al conjunto total de individuos, unidades o elementos sobre los cuales se pretende realizar inferencias a partir del estudio.

1.4.5. Tamaño de la Muestra

El tamaño de la muestra corresponde al número de unidades seleccionadas para el estudio, determinado con base en criterios estadísticos que garanticen la precisión y fiabilidad de los resultados.

2. Desarrollo

Partiremos de seleccionar una DB (Data Base), para esto seleccionaremos una base de datos que sea tanto cualitativa como cuantitativa. Para esto buscaremos alguna que nos ofrezca información de cómo se recopilaban los datos.

Optamos por buscar en kaggle[2]. Una vez en el sitio seleccionamos nuestra DB llamada “Amazon Best Sellers[3]”; seleccionamos esta DB debido a que al ser un registro de compras tendremos datos de ambos tipos, cualitativos y cuantitativos.

Ahora, antes de analizar la DB seleccionada, determinaremos nuestro protocolo, tal como se mencionó anteriormente. Empezaremos por considerar los factores pertinentes mencionados en la sección 1.3

2.1. Consideraciones Previas

- **Definir las preguntas:** Los datos son los seleccionados de los productos más vendidos en Amazon, supongamos que nuestro objetivo es lanzar un producto nuevo al mercado, con esta información sabremos en que temporadas se venden mas, cuando podemos esperar mas ventas y cuando la demanda sera mas baja.
- **Establecer Prioridades:** Principalmente nos enfocaremos en determinar que ventas de productos son mas altas o mas bajas, por lo tanto nos interesaran las fechas, la cantidad, el precio al que se vendió y el tipo de producto.
- **Recopilar Datos:** Para la recopilación de datos, para la recopilación de datos podemos usar varias técnicas como puede ser Web Scraping, API's del propio Amazon o herramientas de terceros que ya hagan este proceso, debido a que para hacer Web Scraping debemos de cumplir con los términos de servicio de Amazon, ya que el scraping puede

estar restringido y las API's llevan un registro optaremos por un servicio de un tercero llamado Keppa[4].

- **Consideraciones Extras:** Teniendo en cuenta que son datos de ventas no consideramos que sean datos sensibles con los cuales tratar.

Una vez dicho esto, podemos seguir con la recolección de nuestros datos.

2.2. Recolección de Datos

- **Muestra**

La muestra serán los datos obtenidos por medio de Keppa para generar nuestra DB, con esto podemos obtener datos con un histórico mas preciso.

- **Cobertura**

De la misma manera la cobertura sera los datos que obtengamos sobre las ventas en México.

- **Fecha y Duración**

Debido a la gran cantidad de información tomaremos solo un periodo de tiempo de un año.

- **Población**

La población sera la proporcionada por el mismo sitio, ya que este genera datos de todo el historial por región.

- **Tamaño de la Muestra**

Para el tamaño de la muestra dependerá de la cantidad de datos que queramos y se nos permita descargar, ya que son ventas en tiempo propondremos un mínimo de 6 meses atrás para que sea nuestro histórico de ventas.

2.3. Propuesta de Protocolo

Para nuestra DB proponemos los siguientes atributos:

- | | |
|----------|-------------------|
| ■ Fecha | ■ Precio de venta |
| ■ Nombre | ■ Descuento |
| ■ Marca | ■ Tienda |

Estos atributos son los necesarios para nosotros ya que necesitamos saber que se vendió, de que marca es, cuando se vendió, en que precio, si es que tuvo descuento, y que tienda o vendedor fue quien vende el producto.

La Fecha nos indica cuando es que nuestro producto fue el mas vendido y nos permite saber por medio de un histórico cuanto tiempo fue tendencia así como si es un producto que constantemente se encuentra entre los mas vendidos. El nombre y la marca nos permiten encontrar de manera precisa el producto que se esta vendiendo, dado que tomemos por ejemplo

una TV, existen cientos de marcas cada una con diferentes modelos es por esto que necesitamos identificar precisamente cual es la mas vendida, ya que las ventas de los modelos mas estándar (Entre 36–50 in.) siempre serán mas vendidos que sus modelos mas grandes (Entre 55–90 in.). El precio de venta es también un punto interesante a considerar ya que con este dato por si solo podemos saber cual fue su precio máximo y mínimo de venta así como su precio promedio, por que puede darse el caso de que un producto alcance un pico de ventas debido a su bajo costo. Por la misma razón es importante saber si se aplico algún descuento y de cuanto fue, ya que existe la opción de que sea un buen producto a un costo elevado por lo que al tener un descuento podremos determinar si es un producto deseado pero que la gente suele comprar solo cuando tenga un costo bajo. Por ultimo la tienda, se refiere al vendedor de nuestro producto, que puede ser la misma marca pero también puede ser un vendedor externo con esto podemos determinar si los descuentos vienen de la marca o si el vendedor prefiere vender mas bajando sus precios, esto podría ser por que un nuevo modelo se anuncio y prefieren vaciar su stock para poder tener el nuevo producto sin tantas perdidas.

3. Resultados

3.1. Comparación de Protocolos

Al explorar la información proporcionada por el autor de esta DB podemos darnos cuenta que el tiempo que se recopilo la información es solo de 3 meses como podemos ver en en la Figura 1, sin embargo se nos hace notar que esto es debido a que cada cierto tiempo los productos mas vendidos cambian, esto nos muestra que para un mismo día existen varios datos diferentes como se ve en la Figura 2.

Coverage

TEMPORAL COVERAGE START DATE	TEMPORAL COVERAGE END DATE	GEOSPATIAL COVERAGE
07/31/2020	09/30/2020	Mexico

Figura 1: Captura del periodo de cobertura

time	Rank	Product Names
2020-07-31 00:38	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 10:52	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 11:00	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 11:28	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 11:49	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 12:10	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 13:31	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 13:51	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 14:12	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 14:33	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 14:53	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 15:14	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 15:35	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 15:56	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 16:16	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 16:37	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-07-31 16:58	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-08-01 17:56	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-08-01 17:57	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-08-01 17:58	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-08-01 18:02	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-08-01 18:03	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-08-01 18:12	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-08-01 18:19	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-08-01 18:21	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate
2020-08-01 18:22	1	Echo Dot (3ra generación) - Bocina inteligente con Alexa - Granate

Figura 2: Captura de la DB filtrando por producto mas vendido

En lo que respecta a la Muestra vemos que los datos están divididos por categorías, de productos las cuales son:

- amazon devices ■ electronics ■ music ■ software
- automotive ■ grocery ■ musical instruments ■ sports
- baby ■ handmade ■ office product ■ tools
- books ■ hpc ■ pet supplies ■ toys
- digital text ■ industrial ■ shoes ■ videogames
- dvd ■ kitchen

Esto nos da mas claridad en los datos que estamos viendo y a su vez nos permite ser mas precisos con el modelo que vayamos a entrenar de manera que podría manejar estas mismas categorías o también tomarlos todos en cuenta para tener un panorama mas general.

También podemos ver una diferencia en la cobertura, dado que se planteo solo analizar datos en México, sin embargo se nos dan datos de ventas de Brasil, esto podría darnos una mayor perspectiva de las ventas en dos grandes países de Latinoamérica.

Por ultimo podemos ver que las muestras podríamos tomarlas dependiendo de la categoría que estemos observando esto nos da varias muestras para trabajar según el sector a analizar.

4. Discusión

Al visualizar la DB así como el protocolo sugerido en la pagina de kaggle[3] observamos que el enfoque fue ligeramente diferente, esto nos lleva a tener varios pros y contras en cada protocolo, tanto el sugerido como el que se uso para recopilar la base de datos.

Tomando de punto de partida que en el protocolo sugerido no se tomo en cuenta la rapidez con la que los productos mas vendidos cambian, dado que la base de datos tiene varios datos según la hora esto nos ofrece información mas precisa. De la misma manera nos muestra los 50 productos más vendidos, esto nos permitiría hacer un modelo predictivo para determinar con que frecuencia los productos van escalando en su posición.

time	Ran	Product Names
2020-07-31 00:38	1	Echo Dot (3ra generación) - Bocina inteligente con Al
2020-07-31 00:38	2	Fire TV Stick - Reproductor de media con control rem
2020-07-31 00:38	3	Amazon Smart Plug compatible con Alexa
2020-07-31 00:38	4	E-reader Kindle Paperwhite, resistente al agua, color
2020-07-31 00:38	5	Nuevo e-reader Kindle, ahora con una luz frontal, col
2020-07-31 00:38	6	Echo Spot - Reloj inteligente con Alexa - Negro
2020-07-31 00:38	7	Echo Show 5 - Pantalla compacta de 5.5" con Alexa -
2020-07-31 00:38	8	Presentamos Echo Show 8 - Pantalla inteligente HD d
2020-07-31 00:38	9	Echo (3ra generación) - Bocina inteligente con Alexa
2020-07-31 00:38	10	Cable USB Amazon PowerFast - para una carga más r
2020-07-31 00:38	11	Funda de piel premium para Nuevo Kindle Paperwhit
2020-07-31 00:38	12	Nuevo Kindle Oasis, ahora con luz cálida ajustable, 8
2020-07-31 00:38	13	Funda de piel para Kindle (sólo sirve para Kindle 10ª g
2020-07-31 00:38	14	Echo Studio - Bocina inteligente de alta fidelidad con
2020-07-31 00:38	15	Presentamos Echo Flex - Mini bocina inteligente de e
2020-07-31 00:38	16	Echo Show 5 base ajustable- Blanco
2020-07-31 00:38	17	Echo Show 8 Base Ajustable - Blanca
2020-07-31 00:38	18	Echo Plus (2da generación) - Sonido de alta calidad y
2020-07-31 00:38	19	Echo Wall Clock - Consulta los timers de un vistazo -
2020-07-31 00:38	20	Nuevo Amazon eero router de malla wifi
2020-07-31 00:38	21	Presentamos Ring Indoor Cam, cámara de seguridad d
2020-07-31 00:38	22	Funda de piel y resistente al agua para Nuevo Kindle
2020-07-31 00:38	23	La nueva cámara de seguridad Ring Stick Up Cam Batt
2020-07-31 00:38	24	Nuevo Ring Video Doorbell 3 — con video 1080p HD, c
2020-07-31 00:38	25	Funda de piel premium para Nuevo Kindle Paperwhit

Figura 3: Captura de la DB top 25 del 31 de Julio de 2020 a las 00:38

Otro punto a tomar en cuenta son las estrellas y los reviews de cada producto, es importante saber esto ya que cada una de estas dos categorías por si solas no son concluyentes, dado que un producto podría tener 5 estrellas pero pocos reviews esto hace que si no sean tan confiables por si solas. Por otro lado si tomamos solo los reviews no podríamos identificar si son positivos o negativos es decir podríamos tener un producto con muchos reviews negativos si ignoramos las estrellas. Es por esto que debemos saber la calidad de los productos teniendo estos dos valores en cuenta, lo ideal seria tener arriba de 1000 reviews y mas de 4 estrellas para determinar si un producto es bueno.

Por ultimo el precio es abordado de manera similar a la propuesta sin embargo aquí se separa en dos categorías “Price std or min” y “Max prices” esto nos permite observar de manera mas directa la información propuesta en nuestro protocolo, sin embargo si lo que se busca es tener una mayor eficiencia para nuestro modelo podríamos combinar estas columnas como se propuso, pero esto dependerá del enfoque que tomemos.

5. Conclusión

Principalmente se puede observar que el planteamiento de un protocolo debe hacerse a conciencia sobre lo que queremos y necesitamos obtener, sin embargo no debe ser tomado de manera estricta ya que al realizar la comparación de protocolos pude observar que mi protocolo pudo haber sido mejor si tomaba en cuenta otros atributos que pase por alto, como los reviews y las estrellas. De la misma manera se considero no usar datos sensibles o personales, sin embargo

y de ser posible considero que valdría la pena incluir un campo de la zona que registro mas compras de cada producto, esto nos podría ofrecer información indirecta sobre cada compra, por ejemplo durante un periodo de calor en zonas generalmente cálidas podría registrarse un incremento de ventas de ventiladores. Esto nos da mas retroalimentación sobre por que se vuelven tendencia los productos.

Esto quiere decir que un protocolo se puede retroalimentar o tener correcciones significativas para mejorar, dependiendo de en que queramos enfocarnos, es por esto que se determinan que datos son los indispensables pero teniendo en cuenta que mientras hacemos nuestra investigación podemos toparnos con datos que no se consideraron y que podrían ser de ayuda para alcanzar nuestro objetivo.

Otro punto importante que no se dimensiono correctamente fue la muestra ya que la DB obtenida solo tiene datos de 3 meses sin embargo no es para nada pequeña. Sin embargo se propuso una muestra de años, si quisiéramos usar el mismo formato de horas y días nos presentaría un escenario donde claro que seria mas preciso nuestro modelo y nuestra predicción de las tendencias, sin embargo también implica un mayor costo de procesamiento, si se cuentan con los recursos esto no seria un problema, pero en caso de que nos interese que sea mas rápido y no tengamos el poder de computo necesario habría que limitar la información, de nuevo esto dependerá de lo que estemos pensando en desarrollar.

6. Bibliografía

Referencias

- [1] Marco Antonio Aceves Fernandez. *Inteligencia Artificial Para Programadores Con Prisa*. Universo de Letras, 2021.
- [2] Anthony Goldbloom. *Kaggle*. 2010. URL: <https://www.kaggle.com> (visitado 12-02-2025).
- [3] Edward Toledo Lopez. *Amazon Best Sellers*. 2020. URL: <https://www.kaggle.com/datasets/edwardtoledolpez/amazon-mexico-top-50-best-sellers?select=mexico> (visitado 12-02-2025).
- [4] *Keepa*. 2011. URL: <https://keepa.com/> (visitado 12-02-2025).