



Universidad Autónoma de Querétaro
Facultad De Ingeniería



**FACULTAD DE
INGENIERÍA**

Outliers y Datos Sintéticos en Seguros de Gastos Médicos

Aprendizaje Automático Reto 1

P R E S E N T A

Ing. Daniel Eduardo González Alvarado

Profesor

Dr. Marco Antonio Aceves Fernández

3 de Marzo de 2025

Índice

1. Introducción	1
1.1. Outliers	1
1.2. Imputación de Datos o Datos Sintéticos	2
1.3. Técnicas por información externa o deductiva	2
1.4. Técnicas deterministas	2
1.4.1. Imputación por regresión	2
1.4.2. Imputación de la media o moda	2
1.4.3. Imputación por media de clases	2
1.4.4. Imputación por vecino mas cercano	3
1.4.5. Imputación por algoritmo de EM(Expectation Maximization)	3
1.5. Técnicas estocásticas	3
1.5.1. Imputación Aleatoria	3
1.5.2. Imputación Secuencial	3
1.6. Método de la ruleta:	3
2. Desarrollo	3
2.1. Conociendo los Datos	4
2.2. Categorización	6
2.3. Outliers	6
2.4. Datos Sintéticos	8
3. Resultados	8
3.1. Outliers	9
3.1.1. Outliers en Prima	9
3.1.2. Outliers en Adicionales	10
3.1.3. Outliers en Pago Total	11
3.2. Distribución de datos sintéticos	13
3.2.1. Infantes	13
3.2.2. Adultos Mayores	14
3.2.3. Jóvenes	15
4. Discusión	15
4.1. Outliers	15
4.1.1. Prima	15
4.1.2. Adicionales	16
4.1.3. Pago Total	16
4.2. Distribución de los Datos	16
4.2.1. Infantes	16
4.2.2. Adultos Mayores	17
4.2.3. Jóvenes	17
5. Conclusión	17
6. Bibliografía	18

1. Introducción

Los seguros de gastos médicos son un tipo de póliza de seguro diseñada para proteger a la persona asegurada y, en muchos casos, a sus familiares, ante la eventualidad de tener que cubrir gastos económicos derivados de atención médica, ya sea por enfermedades, accidentes o tratamientos médicos necesarios. Este tipo de seguros es una herramienta financiera que brinda tranquilidad y seguridad, ya que permite acceder a servicios de salud sin preocuparse por los costos elevados que pueden surgir en situaciones imprevistas.

Estos seguros operan bajo un sistema de pagos periódicos, conocidos como primas, que el asegurado realiza comúnmente de manera mensual. A cambio, la aseguradora se compromete a cubrir una parte significativa de los gastos médicos que puedan surgir, siempre y cuando estos estén dentro de los términos y condiciones establecidos en la póliza. La cantidad máxima que la aseguradora pagará en caso de un siniestro se conoce como suma asegurada, la cual varía dependiendo del plan contratado.

El monto de la prima y la suma asegurada dependen de varios factores, principalmente:

- **Edad:** A mayor edad, el riesgo de enfermedades aumenta, lo que puede elevar el costo de la prima.
- **Género:** En algunos casos, las primas pueden variar según el género debido a diferencias en riesgos médicos asociados.
- **Lugar de residencia:** El costo de los servicios médicos varía según la región o país.
- **Ocupación:** Las personas con trabajos de alto riesgo pueden pagar primas más altas.
- **Historial médico:** Las condiciones de salud preexistentes o antecedentes médicos pueden afectar el costo y la cobertura.
- **Tipo de plan:** Los planes más completos, que incluyen mayores coberturas y menores deducibles, suelen tener primas más elevadas.

Debemos tener en cuenta los principales componentes de un seguro:

- **Prima:** Es el pago periódico que realiza el asegurado para mantener activa la póliza.
- **Suma asegurada:** Es el monto máximo que la aseguradora pagará por los gastos médicos durante el periodo de vigencia del seguro.
- **Deducible:** Es la cantidad que el asegurado debe pagar de su bolsillo antes de que el seguro comience a cubrir los gastos.
- **Coberturas adicionales:** Algunos planes incluyen servicios como atención dental, oftalmológica, maternidad o medicina preventiva.

1.1. Outliers

La calidad de los datos es fundamental para garantizar que los análisis y decisiones basados en ellos sean precisos y confiables. Comúnmente, los datos suelen tener errores al momento de ser capturados, confusión de caracteres o simplemente que los datos son privados y se censuran.

Entre los problemas más comunes que afectan la calidad de los datos se encuentran los valores faltantes, que pueden distorsionar los resultados si no se manejan adecuadamente; los problemas de cardinalidad, que surgen cuando hay una desproporción en la distribución de categorías dentro de un conjunto de datos, dificultando el análisis [1]; y los outliers, que son valores atípicos que se desvían significativamente del resto de los datos. Estos últimos son especialmente críticos, ya que pueden sesgar los análisis, afectar el rendimiento de los modelos predictivos y llevar a conclusiones erróneas si no se identifican y tratan correctamente. Por ello, detectar y gestionar los outliers es esencial para mantener la integridad y utilidad de los datos.

1.2. Imputación de Datos o Datos Sintéticos

La Imputación de datos es una técnica para reemplazar valores perdidos en base a los valores que sí tenemos. El principal objetivo de la imputación es tener una base de datos con la menor cantidad de datos faltantes y que mantenga la misma distribución de los datos existentes. Existen 3 clasificaciones principales, siendo:

- Técnicas por información externa o deductiva.
- Técnicas deterministas.
- Técnicas aleatorias o estocásticas.

1.3. Técnicas por información externa o deductiva

Esta técnica se realiza cuando los datos faltantes pueden deducirse a partir de otras instancias.

1.4. Técnicas deterministas

Estas técnicas funcionan cuando, de acuerdo a las mismas condiciones de los datos, producen las mismas respuestas. Entre estas técnicas se encuentran:

1.4.1. Imputación por regresión

Se ajusta un modelo que suele ser lineal; sin embargo, puede ser polinomial. Los datos faltantes se toman del ajuste que se realizó por medio de la regresión.

1.4.2. Imputación de la media o moda

Con este método llenaremos las instancias faltantes con la media en caso de los datos cuantitativos y la moda para los datos cualitativos. Es importante mencionar que esto reduce la varianza, afectando la distribución de los datos.

1.4.3. Imputación por media de clases

Esta técnica se realiza por cada clase del mismo atributo. Se calcula la media de las instancias que tienen valor por cada clase y se llena con el valor faltante parra cada una de las clases.

1.4.4. Imputación por vecino mas cercano

Se calcula la distancia entre la instancia a imputar, usualmente por medio de la distancia euclidiana y los datos que sí tenemos. Una vez que calculamos el dato mas cercanos se utiliza para imputar la instancia faltante.

1.4.5. Imputación por algoritmo de EM(Expectation Maximization)

Es un método iterativo muy utilizado en estadística, el cual consiste en estimar los parámetros para máxima semejanza donde el modelo depende de variables no observadas.

1.5. Técnicas estocásticas

Estas son técnicas de imputación que al repetir el modelo bajo las mismas condiciones siempre arrojan resultados diferentes, por lo cual no son tan recomendables ya que no podemos determinar si la imputación es buena o no. Algunas de estas técnicas son:

1.5.1. Imputación Aleatoria

Para esta técnica tomamos a partir del menor hasta el mayor valor que se encuentra en ese atributo. Posteriormente, se selecciona un número que esté en el intervalo de ese atributo de manera aleatoria.

1.5.2. Imputación Secuencial

Este método funciona tomando de manera secuencial datos que ya se tienen para reemplazar los datos faltantes. Se comienza desde un dato inicial de manera aleatoria y se reemplaza el dato faltante con ese dato inicial, después se toma el siguiente dato que se tiene y se reemplaza con el siguiente dato faltante y así sucesivamente.

1.6. Método de la ruleta:

Es una técnica de selección aleatoria ponderada donde cada dato tiene una probabilidad de ser seleccionado proporcional a su peso o importancia. Se utiliza comúnmente en algoritmos evolutivos o para generar datos sintéticos que respeten distribuciones específicas. Por ejemplo, si ciertos valores son más frecuentes en los datos reales, el método de la ruleta asegura que tengan mayor probabilidad de aparecer en los datos sintéticos.

2. Desarrollo

Para este reto partimos de una DB (Data Base) compartida sobre seguros de gastos médicos. Una vez que cargamos los datos nos enfocaremos primeramente en analizarlos de manera general para ver que información tenemos y que conocemos a partir de esta.

	id	Edad	Genero	Plan	No_Personas	Prima	Adicionales	Suma_Asegurada (en millones)	Deducible
0	1	30	F	Individual	1	11400	1239.95	31.5	24000
1	2	44	M	Individual	1	13250	0.00	170.0	24000
2	3	24	M	Familiar	2	33419	1170.95	31.5	35000
3	4	41	M	Individual	1	13250	1885.14	31.5	24000
4	5	28	M	Individual	1	10650	11203.11	170.0	35000

Figura 1: Primeros registros de la DB original

2.1. Conociendo los Datos

En un primer vistazo podemos ver los atributos con los cuales vamos a trabajar los cuales son:

- id: Identificador de cada registro ya que no se manejan información privada como nombres.
- Edad: Edad de la persona asegurada.
- Genero: Genero de la persona asegurada.
- Plan: Tipo del plan del seguro.
- No_Personas: Numero de personas aseguradas.
- Prima: Costo mensual del seguro.
- Adicionales: Servicios extras (Opcional)
- Suma_Asegurada (en millones): Valor total cubierto por el seguro.
- Deducible: Monto que el asegurado debe cubrir antes de hacer uso de la suma asegurada.

Como parte de la exploración de los datos optamos por obtener los datos únicos:

```
id          [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14...
Edad        [30, 44, 24, 41, 28, 42, 53, 52, 47, 33, 59, 4...
Genero      [F, M]
Plan        [Individual, Familiar]
No_Personas [1, 2, 3]
Prima       [11400, 13250, 33419, 10650, 34866, 13700, 334...
Adicionales [1239.95, 0.0, 1170.95, 1885.14, 11203.11, 198...
Suma_Asegurada (en millones) [31.5, 170.0, 8.0]
Deducible   [24000, 35000, 50000]
dtype: object
```

Figura 2: Datos únicos de cada atributo de la DB original

Se optó por generar todos los datos únicos, teniendo en cuenta que algunos atributos tendrán un gran rango de valores como es el caso de “Adicionales” o “Prima” sin embargo, es bastante útil notar que tanto la “Suma_Asegurada (en millones)” como el “Deducible” tienen solo 3 valores. Esto será útil para el manejo de la información. Ahora exploraremos un poco mas la tabla:

Columnas con datos variables:

- **id:** Al ser solo identificador debe ser único, por lo cual tenemos tantos valores como registros.
- **Edad:** Puede variar ya que las personas aseguradas pueden tener un rango variado de edades. Cabe remarcar que este es un rango limitado, ya que no solo es imposible que una persona viva más de 120 años, sino que además una persona de esta edad asegurada representa un gran riesgo para las aseguradoras.
- **Prima:** Es el precio que se paga por el seguro, este puede variar dependiendo de otros factores como edad, género, ocupación, etc., por lo cual tenemos varios valores.
- **Adicionales:** El precio por servicios extras que no son obligatorios, pero que se pueden añadir para cubrir un mayor número de situaciones.

Columnas con valores determinados:

- **Género:** Solo puede ser Masculino o Femenino.
- **Plan:** Solo puede ser Individual o Familiar.
- **No_Personas:** Solo se aseguran de 1 a 3 personas.
- **Suma Asegurada:** El seguro solo ofrece 3 montos de seguro: 31.5, 170 o 8 millones.
- **Deducible:** La cantidad a pagar por el asegurado debe ser de 24,000, 35,000 o 50,000.

Valores Máximos y mínimos:

De la misma manera buscamos los datos Máximos y mínimos:

	Columna	Maximo	ID_max	Minimo	ID_min
0	id	10530	10530	1	1
1	Edad	87	5878	0	6680
2	Genero	M	2	F	1
3	Plan	Individual	1	Familiar	3
4	No_Personas	3	16	1	1
5	Prima	50672	1386	8550	28
6	Adicionales	12375.54	31	0.0	2
7	Suma_Asegurada (en millones)	170.0	2	8.0	7
8	Deducible	50000	7	24000	1

Figura 3: Datos máximos y mínimos con id de cada columna

Una vez que tenemos esto generamos dos columnas para tener información extra las cuales son “Pago Total” y “Pago_PP” (Pago por persona) para obtener estas haremos:

$$[\text{Pago_Total}] = [\text{Prima}] + [\text{Adicionales}]$$

$$[\text{Pago_PP}] = \frac{[\text{Pago_Total}]}{[\text{No_Personas}]}$$

2.2. Categorización

Dado que estamos trabajando con Seguros Médicos consideraremos el caso real donde los seguros se ofrecen según la edad por lo que segmentaremos nuestra DB de tal manera que generaremos 4 categorías o bien 4 tipos de seguros, para niños (0-15 años), jóvenes (16-30 años), adultos (31-60 años) y adultos mayores (61 y mayores).

2.3. Outliers

Ya que tenemos segmentado por “Etapa” de la vida, tenemos un tipo de seguro para cada uno, por lo cual con estas nuevas categorías ya podemos encontrar los outliers de las categorías que nos interesan, las cuales son Edad, Prima, Adicionales, Pago Total.




Figura 4: Outliers y densidad de datos en Edad




Figura 5: Outliers y densidad de datos en Prima




Figura 6: Outliers y densidad de datos en Adicionales




Figura 7: Outliers y densidad de datos en Pago Total

Con estas gráficas podemos fácilmente ver la cantidad de datos outliers por atributo en las gráficas de caja, y en las gráficas de violín, además de mostrarnos esos outliers, también nos permiten ver cuál es la distribución de los datos. Estos outliers son obtenidos a partir de la base de datos completa. Es importante mencionar que estos outliers pueden no ser validos, recordemos que el hecho de que tengamos un dato fuera de nuestra media no lo convierte en un dato invalido ya que este puede ser valido y atípico. Es por esto que se decidió segmentar por edad, ya que generalmente los seguros al tener varios criterios pueden variar su costo y un dato que en general es un outlier puede que en su segmento no lo sea.

Una vez que segmentamos los datos podemos obtener los outliers por tipo de seguro basado en la etapa, a su vez volveremos a dividir en categorías de genero otro criterio importante en los seguros. Con esto obtendremos de nuevo nuestros outliers por etapa ademas de contar los resultados por genero. Podemos ver los outliers en la sección 3.1

2.4. Datos Sintéticos

Una vez que obtuvimos los outliers con los datos “Reales” procedemos a generar nuestros datos sintéticos, para esto hacemos un conteo de nuestras categorías.

Etapas	
Adultos	8244
Jóvenes	1418
Adultos Mayores	744
Infantes	124

Figura 8: Conteo de valores por Etapa

Como podemos en la Figura 8 nuestros datos están muy desbalanceados teniendo la mayor cantidad en el segmento de “Adultos”, por lo cual generaremos datos para tratar de tener una muestra más grande. Sin embargo, es importante tomar en cuenta que la distribución de los datos antes y después de imputar debe mantener la misma tendencia, por lo cual si esta distribución varía mucho debemos reducir los datos imputados.

Creamos una función para generar los datos sintéticos de Género y Plan de manera que sea aleatorio entre nuestras categorías. Al asignarle el tipo de plan aprovechamos para determinar si es plan es Familiar asignaremos un número de personas entre 2 y 3.

Definimos una función que nos generará un nuevo DataFrame con el número de registros que queramos para nuestros datos sintéticos.

Para nuestros DataFrames se tomaron las siguientes consideraciones:

- **Infantes:** Al ser nuestra muestra más pequeña, generaremos el doble de datos, es decir, el 100 %.
- **Adultos Mayores:** Al tener más datos, solo generaremos el 33 % de datos para poder aumentar nuestra muestra y tratar de balancear al mismo tiempo.
- **Jóvenes:** Al igual que el caso anterior y dado que tienen una muestra más grande, solo generaremos un 25 % más de datos.
- **Adultos:** Dado que es nuestra muestra más grande, no generaremos más datos aquí.

Creamos `df(DataFrames)` con la cantidad de registros propuestos con una función que nos ayude a generar nuestros datos sintéticos en los valores NaN de nuestro nuevo `df` por medio del método de la ruleta.

Este método nos permite calcular la probabilidad de aparición de cada dato; esto nos permite imputar datos nuevos que mantengan la misma distribución. Una vez hecho esto concatenamos el `df` sintético con el `df` segmentado por edad.

Una vez hecho esto graficamos nuestra distribución antes y después para comparar que la distribución se mantiene. Podemos ver la distribución en la sección 3.2

3. Resultados

Los Outliers obtenidos con nuestro análisis fueron los siguientes:

3.1. Outliers

3.1.1. Outliers en Prima




Figura 9: Outliers de Prima en Infantes




Figura 10: Outliers de Prima en Jovenes




Figura 11: Outliers de Prima en Adultos




Figura 12: Outliers de Prima en Adultos Mayores

3.1.2. Outliers en Adicionales




Figura 13: Outliers de Adicionales en Infantes




Figura 14: Outliers de Adicionales en Jóvenes




Figura 15: Outliers de Adicionales en Adultos




Figura 16: Outliers de Adicionales en Adultos Mayores

3.1.3. Outliers en Pago Total




Figura 17: Outliers de Pago Total en Infantes




Figura 18: Outliers de Pago Total en Jóvenes




Figura 19: Outliers de Pago Total en Adultos




Figura 20: Outliers de Pago Total en Adultos Mayores

Por ultimo teniendo en cuenta la cantidad de registros en cada categoría y los outliers podemos sacar esta relación segun el pago total:

Etapa	Registros	Outliers	Porcentaje de Outliers
Infantes	124	9	7.25
Jóvenes	1418	94	6.62
Adultos,	8244	597	7.24
Adultos Mayores	744	50	6.72

Tabla 1: Porcentaje de outliers por etapa

3.2. Distribución de datos sintéticos

Después de crear datos sintéticos y agregarlos a nuestro df anterior comprobamos la distribución para asegurarnos de que no haya sido modificada.

3.2.1. Infantes




Figura 21: Distribución de datos en edad de infantes antes y después de los datos sintéticos




Figura 22: Distribución de datos en prima de infantes antes y después de los datos sintéticos




Figura 23: Distribución de datos en Adicionales de infantes antes y después de los datos sintéticos

3.2.2. Adultos Mayores




Figura 24: Distribución de datos en edad de adultos mayores antes y después de los datos sintéticos




Figura 25: Distribución de datos en prima de adultos mayores antes y después de los datos sintéticos




Figura 26: Distribución de datos en adicionales de adultos mayores antes y después de los datos sintéticos

3.2.3. Jóvenes




Figura 27: Distribución de datos en edad de jóvenes antes y después de los datos sintéticos




Figura 28: Distribución de datos en prima de jóvenes antes y después de los datos sintéticos




Figura 29: Distribución de datos en adicionales de jóvenes antes y después de los datos sintéticos

4. Discusión

4.1. Outliers

4.1.1. Prima

Como podemos ver en la sección de resultados 3.1 en la figura 9 podemos ver que la distribución de los datos es demasiado grande ya que con la gráfica de caja no alcanzamos a ver la caja en si, esto indica que nuestros datos están por debajo de 10,000 pero están muy separados por

lo que no podemos verlos claramente, sin embargo los outliers si podemos verlos determinando que hay mas de estos en las **mujeres**.

Para el caso de los jóvenes en la figura 10 vemos un comportamiento de los datos similar al de los infantes por lo que no vemos la caja pero los outliers se ven mas distribuidos, en esta caso aunque no se ve a simple vista en el código podemos ver que los outliers están mas balanceados siendo 211 en **mujeres** y 194 en hombres.

Para los adultos en la figura 11ya podemos ver la caja en el gráfico y una vez más vemos que los outliers son similares pero con tendencia a ser más en las **mujeres** teniendo 343 y los hombres 316.

Por ultimo los adultos mayores en la figura 11 vemos que existen menos outliers y la tendencia de la mayoría de **mujeres** se mantiene con 87 y los hombres con 80.

4.1.2. Adicionales

En la figura 13 observamos que no hay outliers, esto indica que no tenemos datos atípicos en infantes.

Para los jóvenes podemos ver en la figura 14 los primeros outliers pero que se encuentran dos en hombres y dos en mujeres.

Estos outliers equilibrados podemos verlos de nuevo en la figura 15 con cuatro de cada lado.

Los adultos mayores como se puede ver en la figura 15 solo tienen un outlier en los hombres.

4.1.3. Pago Total

En este punto y con lo anterior podemos deducir que el pago total al ser la suma de la prima más los adicionales mantendrán la tendencia anterior es decir que las **mujeres** tienen más outliers.

4.2. Distribución de los Datos

Es importante el mantener la misma distribución después de generar datos sintéticos para asegurarnos que nuestros datos se mantengan lo mas similares posibles y tengamos una muestra más grande pero con el mismo comportamiento. Recordemos que los atributos Edad, Prima y Adicional fueron los que se generaron por medio del método de la ruleta.

4.2.1. Infantes

Como podemos ver en las sección 3.2.1 las distribuciones antes y después se mantienen pero contamos con una mayor cantidad de datos, sin embargo podemos ver en la Figura 21 un pequeño pico empieza a surgir entre los 3 y 4 años este es un indicativo de que los datos empiezan a cambiar nuestra distribución por lo cual no es recomendable seguir generando más datos. De la misma manera observamos algo similar en la Figura 23 donde después del segundo pico podemos ver como la curva de disminución tiene un pequeño pico.

Estas variaciones son esperadas por la gran cantidad de datos generados, recordemos que se generaron el 100 % de datos para poder tener el doble. Es decir si generamos mas de eso la distribución se vería seriamente afectada.

4.2.2. Adultos Mayores

En la sección 3.2.2 vemos que es donde se mantiene una mayor calidad en la distribución ya que aunque tenemos más datos esta se mantiene casi igual, recordemos que aquí se generaron un tercio de los datos originales.

4.2.3. Jóvenes

En la sección 3.2.3 al solo generar el 25 % de los datos vemos que nuestra distribución es prácticamente la misma.

5. Conclusión

Como pudimos ver en la sección 3.1 podemos determinar que los outliers existen principalmente en los infantes y los adultos, sin embargo quienes tienen mas datos atípicos son las mujeres, en este caso podemos decir que hay varios factores, desde que tienen más situaciones como partos, cáncer de mama, por mencionar algunos. Sin embargo también hay que mencionar que esto puede ser por que la mayoría de los seguros sean contratados por las mujeres ya que también suelen ser más responsables con su salud que los hombres ademas de tener esta planeación a futuro.

Finalmente podemos determinar basados en la tabla 1 que una estrategia de negocios seria promocionar seguros especiales para niñas ya que al contar con más outliers podemos ver que son un sector altamente rentable. Tanto como para apoyar a este sector como para poder subir precios ya que podemos ver que la gente suele pagar más en este campo.

6. Bibliografía

Referencias

- [1] Marco Antonio Aceves Fernandez. *Inteligencia Artificial Para Programadores Con Prisa*. Universo de Letras, 2021.