




UNIVERSIDAD AUTÓNOMA DE QUERÉTARO
FACULTAD DE INGENIERÍA




DIPF
POSGRADO
INGENIERÍA

Localización avanzada de fuentes de señales de electroencefalograma mediante técnicas de computación avanzada



PRESENTA:

ING. DANIEL EDUARDO GONZÁLEZ ALVARADO


Junio 2026



INTRODUCCIÓN



UNIVERSIDAD AUTÓNOMA DE QUERÉTARO
FACULTAD DE INGENIERÍA



DIPF
POSGRADO
INGENIERÍA




FIGURA 1. REPRESENTACIÓN DE UN ELECTROENCEFALOGRAMA.





FIGURA 2. SEÑALES OBTENIDAS DE UN EEG

Los métodos tradicionales, como **MNE**, **sLORETA** o **VARETA**, ofrecen soluciones, pero suelen presentar baja resolución espacial, sensibilidad al ruido y dificultad para distinguir fuentes profundas o cercanas entre sí.




FIGURA 3. REPLICA 3D DE CEREBRO HUMANO

PLANTEAMIENTO DEL PROBLEMA



UNIVERSIDAD AUTÓNOMA DE QUERÉTARO
FACULTAD DE INGENIERÍA



DIPF
POSGRADO
INGENIERÍA

El EEG registra la actividad eléctrica del cerebro desde el exterior, pero no indica directamente dónde se originan esas señales dentro del cerebro.

Diferentes configuraciones internas pueden producir patrones muy similares en los electrodos, lo que hace que la localización de fuentes neuronales sea un problema ambiguo y difícil de resolver.





FIGURA 4. EJEMPLOS DE AREAS DE ACTIVACION DEL CEREBRO

PLANTEAMIENTO DEL PROBLEMA



UNIVERSIDAD AUTÓNOMA DE QUERÉTARO
FACULTAD DE INGENIERÍA



DIPF
POSGRADO
INGENIERÍA

- El EEG mide la actividad eléctrica del cerebro desde el exterior, con electrodos en el cuero cabelludo.
- El problema inverso consiste en intentar descubrir dónde dentro del cerebro se generó esa actividad.
- El reto es que muchas configuraciones internas pueden producir señales muy parecidas, por lo que no existe una única solución evidente.




FIGURA 4. REPRESENTACION DE MODELO INVERSO

En otras palabras: Medimos la consecuencia (las señales), pero queremos averiguar la causa (la ubicación exacta de la fuente), y eso es matemáticamente ambiguo y difícil.

HIPOTESIS

El uso de un modelo híbrido de deep learning entrenado con datos sintéticos permitirá mejorar la precisión en la localización de fuentes neuronales en comparación con los métodos clásicos (MNE, sLORETA, VARETA), incluso en condiciones con ruido y variaciones anatómicas

OBJETIVOS


General

Desarrollar un modelo híbrido de deep learning capaz de mejorar la precisión en la localización de fuentes neuronales a partir de señales EEG sintéticas.

OBJETIVOS

Especificos

- Generar un dataset sintético de señales EEG utilizando modelos de cabeza y simulaciones de actividad neuronal.
- Diseñar y entrenar un modelo de redes neuronales (CNN + modelos secuenciales) para aprender la relación entre señales EEG y la ubicación de las fuentes.
- Evaluar el desempeño del modelo usando métricas como LE, TE, nMSE, PSNR y compararlo con técnicas clásicas.
- Analizar la robustez del modelo frente a ruido y variaciones en la geometría de la cabeza.
- Determinar si el modelo propuesto supera a métodos tradicionales en precisión y generalización.



Para estimar la ubicación de las fuentes, se formula el problema directo. Esto requiere modelos matemáticos y físicos, como:

- Modelos de cabeza (esférico, BEM, FEM, LSMAC)
- Lead Field Matrix, (posible fuente - señal generada).

El problema inverso es mal planteado, ambiguo y no tiene una única solución debido a:

- La baja conductividad del cráneo.
- La mezcla espacial de señales.
- La superposición de múltiples fuentes.
- La presencia de ruido.





FIGURA 6. METODOLOGIA PROPUESTA



16 Canales = 16 Electrodo

¿Todos los electrodos aportan información relevante?

k= subconjunto


$$C(16, k) = \frac{16!}{(k! * (16 - k)!)}$$



k=8

$C(16, 8) = 12,870$

Evaluando todas las posibles combinaciones


$$2^{16} = 65,536$$
$$2^{32} = 4,294,967,296$$





- Capturan ruido ambiental o artefactos musculares
- Son redundantes porque están muy cerca entre sí
- Tienen baja sensibilidad a fuentes profundas

$$k_{\text{ideal}} = ?$$



Vector Binario (16-32)

k_1	k_2	k_3	...	k_{n-1}	k_e
-------	-------	-------	-----	-----------	-------


Fijamos un $k_{\min}$ de forma que tengamos un subconjunto valido.

Para EEG:


$$k_{\min} = 2 \times Fuentes$$


Con esto proponemos un Algoritmo Genético debido a:

- Maneja bien espacios de búsqueda grandes y discretos
- No requiere que la función objetivo sea diferenciable
- Permite explorar y explotar simultáneamente




- **Impacto en precisión:** Al eliminar electrodos ruidosos o redundantes, el modelo recibe una señal más limpia, lo que se traduce en menor LE y nMSE.
- **Impacto en robustez:** Un subconjunto optimizado es menos sensible a variaciones anatómicas entre sujetos, mejorando la generalización.
- **Impacto en comparación con métodos clásicos:** MNE, sLORETA y VARETA usan configuraciones fijas de electrodos. Un modelo con electrodos seleccionados puede contener más información relevante que una configuración fija.
- **Impacto académico:** Añade una contribución metodológica al estado del arte: no solo se propone un modelo de deep learning, sino también un marco de selección óptima de configuración de adquisición.





UNIVERSIDAD AUTÓNOMA DE QUERÉTARO
FACULTAD DE INGENIERÍA



DIPF
POSGRADO
INGENIERÍA

GRACIAS!

